UNIVERSIDAD AUTÓNOMA DE YUCATÁN

Facultad de Matemáticas · Inteligencia Artificial

QUINTO SEMESTRE

Ejercicio 1 Reporte-percepton multicapa

Alumno: Jaime Manuel Rodríguez Tzuc

Profesor: Dr. Víctor Emanuel Uc Cetina

Reporte

¿Bajó más el error al añadir dos capas, o se estancó / empeoró? ¿Igual en NumPy y Keras?

Con 3 capas el error salió peor y se quedó atorado. Uno pensaría que más neuronas y más capas harían que la red aprendiera mejor, pero pasó lo contrario: la curva de pérdida casi no se movió al principio y después ya no bajó. Lo curioso es que pasa igual tanto en mi versión hecha a mano en numpy como en la de `keras.Sequential`. En las dos, el modelo profundo rindió bastante peor que el original con una sola capa oculta.

2.¿Las curvas de la notebook 01 y de Keras se parecen con la misma topología? Si no, ¿qué diferencias de implementación podrían explicarlo (orden de los datos, inicialización, vectorización, etc.)?

Las dos curvas bajan con la misma tendencia, pero no salen idénticas aunque la arquitectura es la misma (4 x 3 x 3). Esto pasa porque Keras trae varios detalles ya configurados por dentro que en la versión a mano no puse igual. Lo que más se nota en las gráficas:

- Pesos iniciales: Keras usa por default una inicialización más pensada (Xavier/Glorot), y a mano normalmente meto números aleatorios más simples.
- Orden de los datos: Keras baraja los datos en cada época sin que yo haga nada, y en la versión manual no.
- Cálculo por debajo: TensorFlow hace las operaciones con matrices de forma más optimizada, por eso su descenso se ve un poco más suave que el de mis ciclos hechos a mano.

3. Con sigmoides apiladas y MSE, ¿tiene sentido que una red más profunda no aprenda mejor en Iris? Relacionalo con lo que viste en las gráficas.

Tiene sentido, porque esta configuración provoca el desvanecimiento del gradiente. En la retropropagación, el ajuste de cada capa se calcula así:

$\delta^{(l)} = h^{(l)} (1 - h^{(l)}) \cdot$ (error propagado)

La derivada del sigmoide es muy pequeña (máximo 0.25), y como se va multiplicando en cada capa hacia atrás, el gradiente de las primeras capas se vuelve casi cero. Por eso sus pesos casi no se actualizan y el aprendizaje se queda congelado.